

Análise Automática de Radiografias de Escoliose com Deep Learning

Pipeline para Estimação dos Ângulos de Cobb com HRNet-W32

Sérgio Miguel Pereira Moniz (UTAD) | Orientador: António Cunha (UTAD) | Coorientador: António Gouveia (UTAD)

Resumo

A escoliose é uma deformidade tridimensional da coluna cuja avaliação depende da medição manual do ângulo de Cobb em radiografias — processo demorado, subjetivo e com variabilidade inter-observador. Este trabalho propõe um pipeline de Deep Learning que automatiza essa análise: a arquitetura HRNet-W32, treinada no Spinal-AI2024, regrida simultaneamente os três ângulos de Cobb (Torácico Proximal, Torácico Principal, Lombar) e suporta a classificação clínica de severidade. Após 88 épocas, o modelo atinge CMAE médio de 2.62° em validação e 2.83° em teste — quase 50% abaixo da referência state-of-the-art (5–7°).

Introdução

A escoliose afeta 2–3% dos adolescentes e o seu seguimento exige medições reproduzíveis do ângulo de Cobb. A medição manual é morosa e tem variabilidade inter-observador que ultrapassa 5°.

Apresenta-se um pipeline ponta-a-ponta que recebe uma radiografia e devolve os três ângulos de Cobb e a respetiva categoria clínica (Normal, Leve, Moderada, Grave) — apoiando o rastreio populacional, reduzindo o tempo de diagnóstico e padronizando a medição.

Conclusões

O pipeline desenvolvido demonstra que é viável automatizar a análise radiográfica da escoliose com alta precisão. O HRNet-W32 atinge 2.62° de CMAE em validação e 2.83° em teste, superando o estado da arte e ficando bem abaixo da variabilidade inter-observador clínica.

Trabalho futuro: cross-validation k-fold; explorar Vision Transformers e U-Net++; integrar a estimação direta dos 68 keypoints vertebrais com Wing Loss; e validar em radiografias de instituições portuguesas com avaliação clínica cega.

Dataset e Categorias Clínicas




Figura 1: Exemplos do Spinal-AI2024 (subset 5 – teste). Os limiares clínicos do ângulo máximo de Cobb definem 4 categorias: Normal < 10°, Leve 10–25°, Moderada 25–40° e Grave > 40°.

Métodos




Figura 1: Fluxograma da metodologia (treino + inferência)

Figura 2: Fluxograma da metodologia desenvolvida

Dataset — Spinal-AI2024 (~16 000 radiografias, 5 subsets; subsets 1–4 para treino/validação 80/20, subset 5 reservado para teste). Cada imagem está anotada com três ângulos de Cobb.

Pré-processamento — leitura em escala de cinzentos, CLAHE (clip-limit = 3.0), redimensionamento para 512x512 e normalização ImageNet. Em treino: HorizontalFlip, rotação ±10°, RandomBrightnessContrast e GaussNoise.

Modelo — HRNet-W32 (~29 M parâmetros; 4 ramos paralelos [32, 64, 128, 256]) com cabeça de regressão para 3 ângulos. Loss = MSE + Wing Loss ($\alpha=1.0$, $\beta=0.1$).

Treino — AdamW ($\text{lr}=1\times 10^{-3}$, $\text{weight_decay}=1\times 10^{-4}$) com Cosine Annealing Warm Restarts ($T_0=10$, $T_{\text{mult}}=2$). Batch = 8, gradient clipping = 5.0, early stopping (patience = 15). Classificação clínica por categoria: Normal < 10°, Leve 10–25°, Moderada 25–40°, Grave > 40°.

Resultados

Após 88 épocas, o modelo atingiu CMAE médio de 2.62° em validação e 2.83° em teste — quase 50% abaixo do estado da arte ($\approx 5\text{--}7^\circ$). O treino convergiu de forma estável e sem overfitting (Figura 3).

A análise por região (Figura 4) mostra desempenho equilibrado: melhor nos segmentos torácicos ($\approx 2.4^\circ\text{--}2.7^\circ$) e ligeiramente superior na região lombar (3.00° / 3.18°), o que é coerente com a maior variabilidade morfológica desta zona. A diferença reduzida entre validação e teste indica boa generalização.

Tabela 1: Síntese de resultados (Val / Teste)

Métrica	Valor
CMAE médio (Validação)	2.62°
CMAE médio (Teste)	2.83°
CMAE — Torácico Proximal	2.49° / 2.63°
CMAE — Torácico Principal	2.37° / 2.68°
CMAE — Lombar	3.00° / 3.18°
Loss final (Val / Teste)	2.17 / 2.38
Referência SOTA AASCE	$\approx 5\text{--}7^\circ$




Figura 3: (esq.) Evolução do CMAE durante o treino — (dir.) Erro por região (Val. vs. Teste)

